

DM6 : Hachage parfait

Ce DM est facultatif. Il est à rendre pour le 27/02.

L'objectif de ce sujet est d'étudier une structure de données utilisant l'aléatoire. Le contexte est le suivant : on considère un univers U fini et inclus dans \mathbb{N} dans lesquelles les clés d'une table de hachage prennent leurs valeurs. L'ensemble des clés est noté $K \subset U$: il est connu en amont et est de taille n . On souhaite construire une table de hachage dont les clés seront celles de K et garantissant que le nombre d'accès mémoire lors d'une recherche dans cette table se fait en temps constant : on parle alors de hachage parfait.

Partie 1 Classe de fonctions de hachage universelle

Soit E un ensemble fini de fonctions de hachage de U dans $\llbracket 0, m-1 \rrbracket$ pour $m \in \mathbb{N}^*$. On dit que E est une *classe de fonctions de hachage universelle* si, lorsqu'on tire h uniformément aléatoirement dans E , la probabilité que deux clés différentes entrent en collision via h est inférieure à $1/m$; autrement dit :

$$\text{Pour toutes clés } l, k \text{ telles que } l \neq k, \mathbb{P}(h(l) = h(k)) \leq \frac{1}{m}$$

Soit p un nombre premier strictement plus grand que $|U|$ et m un entier. Pour tout $a \in (\mathbb{Z}/p\mathbb{Z})^*$ et tout $b \in \mathbb{Z}/p\mathbb{Z}$, on introduit la fonction h_{ab} suivante (où U est considéré en tant que sous ensemble de $\mathbb{Z}/p\mathbb{Z}$) :

$$h_{ab} : \begin{cases} U \longrightarrow \llbracket 0, m-1 \rrbracket \\ k \longmapsto ((ak + b) \bmod p) \bmod m \end{cases}$$

On note $\mathcal{H}_{pm} = \{h_{ab} \mid a \in (\mathbb{Z}/p\mathbb{Z})^*, b \in \mathbb{Z}/p\mathbb{Z}\}$.

L'objectif de cette partie est de montrer que \mathcal{H}_{pm} est une classe de fonctions de hachage universelle. Dans les questions suivantes, on a fixé un entier premier p plus grand que $|U|$ et un entier m ainsi que deux clés $k, l \in \mathbb{Z}/p\mathbb{Z}$ différentes.

1. Si $a \in (\mathbb{Z}/p\mathbb{Z})^*$ et $b \in \mathbb{Z}/p\mathbb{Z}$, montrer que $r = (ak + b) \bmod p$ et $s = (al + b) \bmod p$ sont différents.
2. Montrer que la fonction suivante est une bijection bien définie :
$$\begin{aligned} \{(a, b) \mid a \in (\mathbb{Z}/p\mathbb{Z})^*, b \in \mathbb{Z}/p\mathbb{Z}\} &\longrightarrow \{(r, s) \in (\mathbb{Z}/p\mathbb{Z})^2 \mid r \neq s\} \\ (a, b) &\longmapsto ((ak + b) \bmod p, (al + b) \bmod p) \end{aligned}$$
3. Montrer qu'étant donné $r \in \mathbb{Z}/p\mathbb{Z}$, le nombre d'éléments $s \in \mathbb{Z}/p\mathbb{Z}$ tels que $r \neq s$ et $r \equiv s \bmod m$ est inférieur à $(p-1)/m$.
4. Dédire des questions précédentes que la classe de fonctions \mathcal{H}_{pm} est universelle.

Partie 2 Hachage sur un niveau

Dans cette partie, on suppose que les n clés sont hachées dans une table de taille $m = n^2$ à l'aide d'une fonction de hachage h choisie uniformément aléatoirement dans une classe de fonctions de hachage universelle à valeurs dans $\llbracket 0, m-1 \rrbracket$ (par exemple, \mathcal{H}_{pm} pour un certain $p \in \mathbb{P}$). On note X la variable aléatoire comptant le nombre de collisions dans cette table (c'est-à-dire le nombre de paires de clés $\{k, l\}$ tels que $h(k) = h(l)$).

5. Majorer l'espérance de X et en déduire que la probabilité d'avoir au moins une collision dans cette table est strictement inférieure à $1/2$.
6. A l'aide du résultat précédent, expliquer comment obtenir une table de taille quadratique en le nombre de clés dans laquelle il est garanti qu'il n'y ait pas de collision.

Partie 3 Hachage sur deux niveaux

La table construite à la question 6 garantit qu'il n'y a pas de collision mais il est regrettable que sa taille soit quadratique en le nombre de clés. On cherche dans cette partie à construire une table sans collisions mais de taille linéaire en n plutôt que quadratique.

Pour ce faire, on commence par hacher les n clés dans une table principale de taille $m = n$ via une fonction h . Puis, dans chaque case de cette table, on construit une table de hachage secondaire de taille $m_i = n_i^2$ via une fonction de hachage h_i où n_i est le nombre de clés qui sont hachées dans la case i par h au premier niveau.

7. Montrer que, si on hache n clés dans une table de taille $m = n$ via h choisie uniformément aléatoirement dans une classe de fonctions de hachage universelle, alors $\mathbb{E} \left[\sum_{i=0}^{n-1} n_i^2 \right] < 2n$ où n_i est la variable aléatoire comptant le nombre de clés hachées dans la case i par h .

Indication : pour tout $k \in \mathbb{N}^$, $k^2 = k + 2\binom{k}{2}$.*

8. Montrer qu'avec la stratégie consistant à hacher sur deux niveaux, la probabilité que l'espace total occupé par l'ensemble des tables secondaires dépasse $4n$ est strictement inférieur à $1/2$.
9. En déduire comment construire une table de hachage sans collision de taille linéaire en le nombre de clés à hacher.